

# Ray. Распределенное обучение

Посевин М.Э. 2022

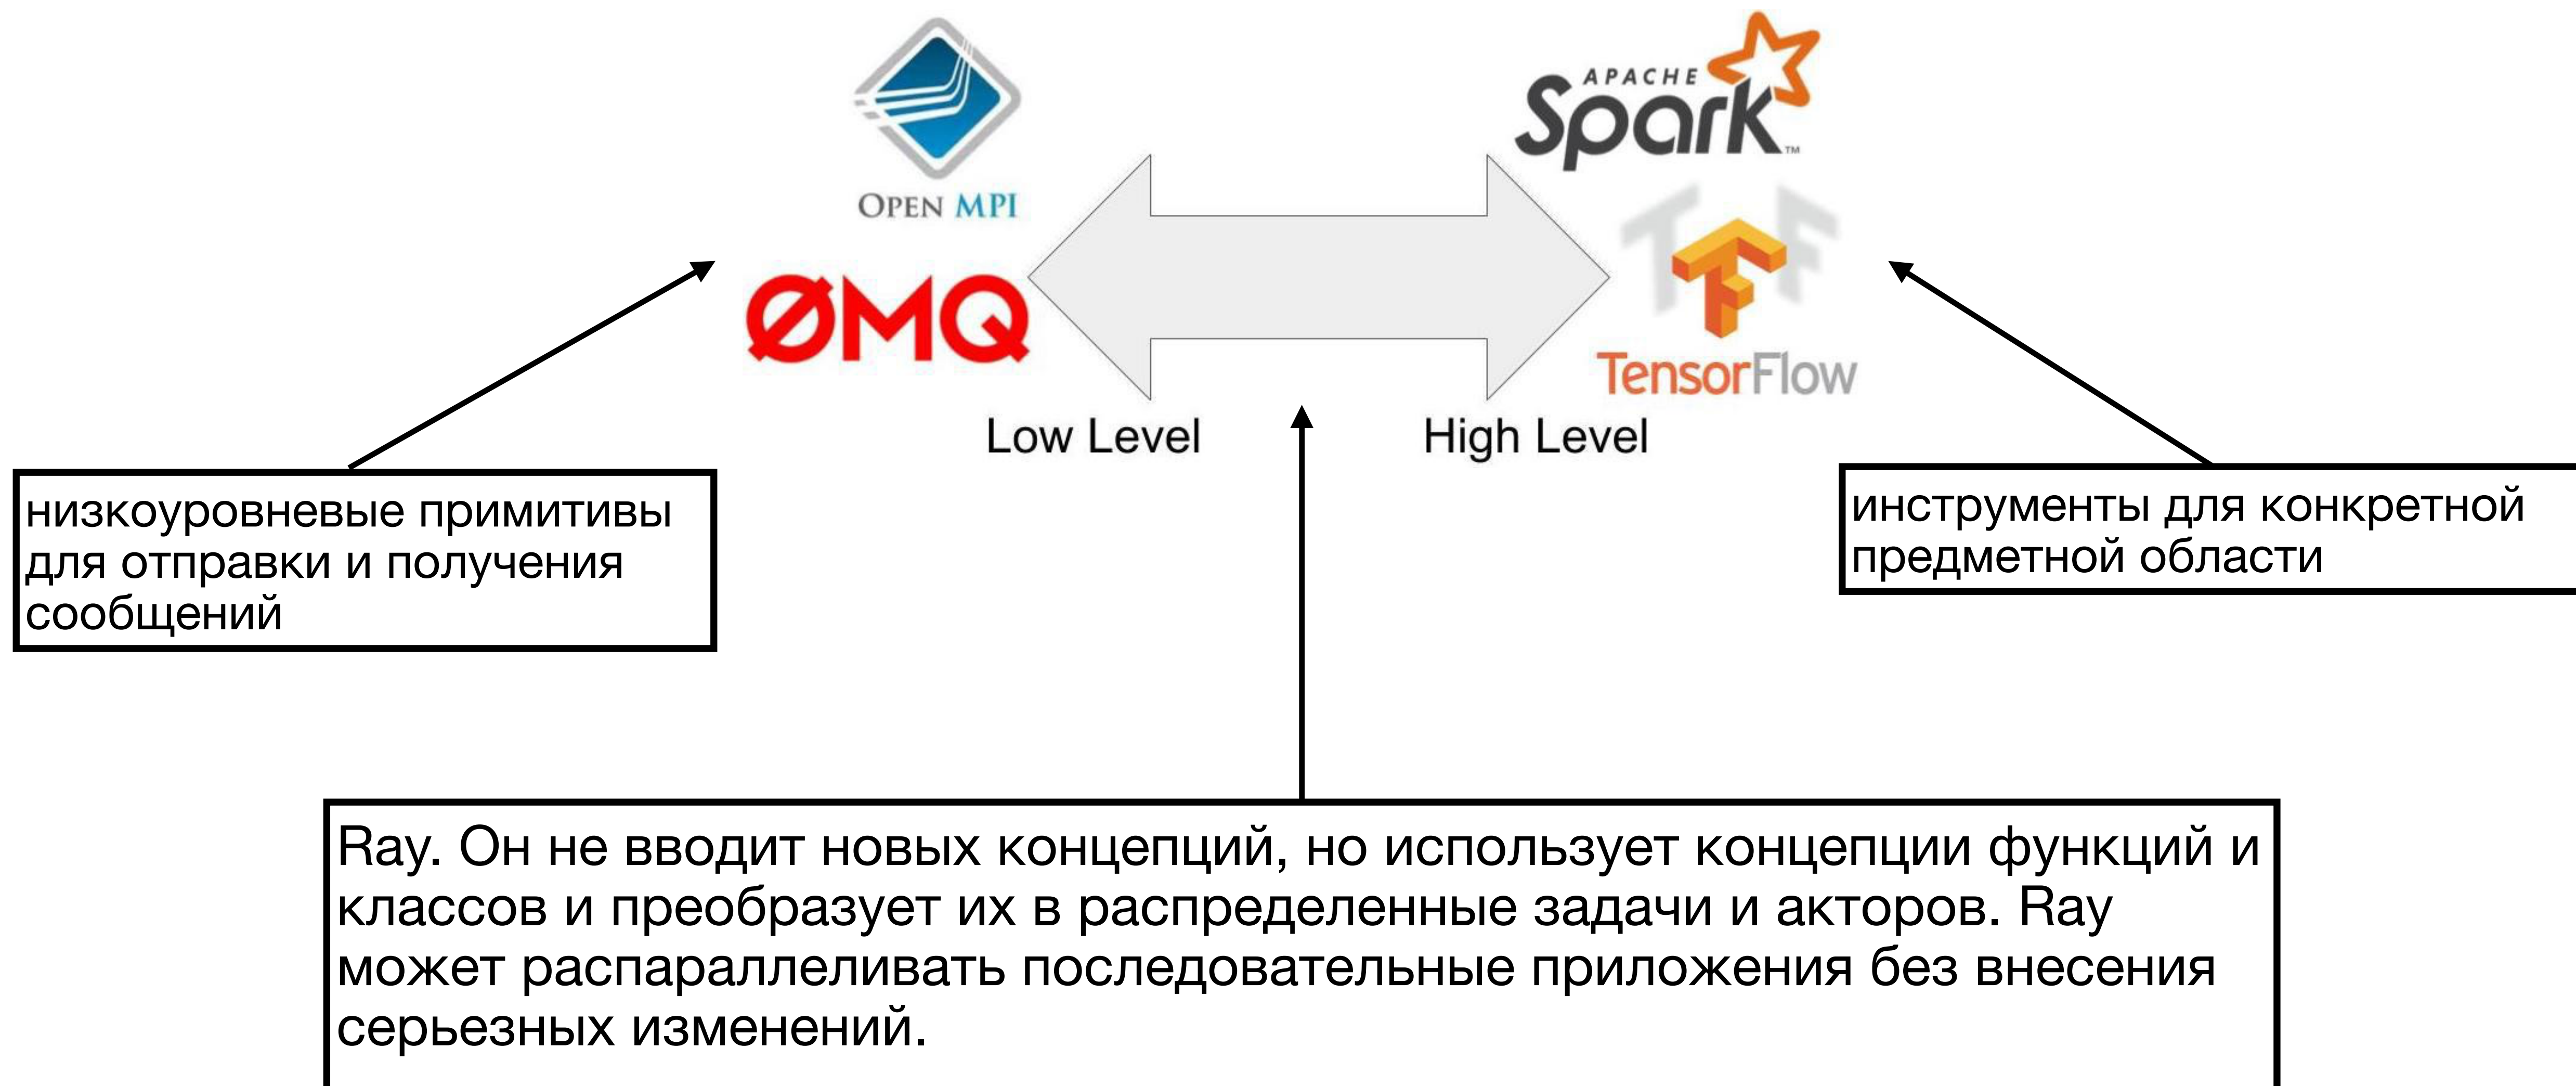
# Ray

Ray представляет собой проект с открытым исходным кодом для параллельных вычислений и распределенной разработки Python.

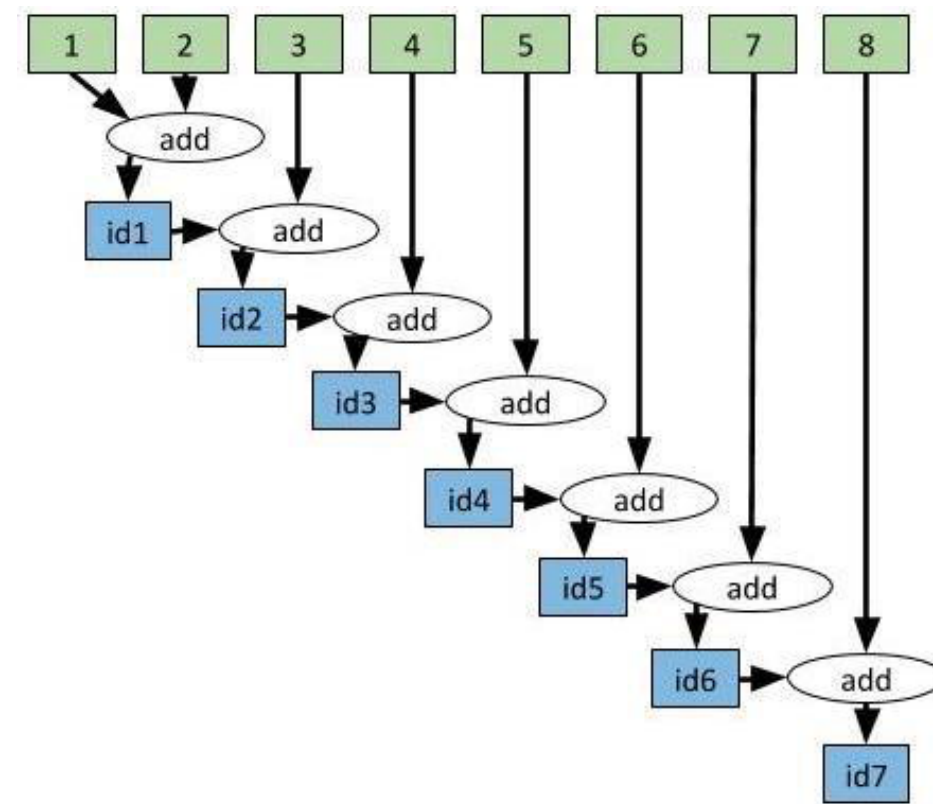
Экосистема Ray состоит из 3 частей:

- базовой системы Ray,
- расширяемых библиотек для машинного обучения (включая собственные библиотеки и сторонние библиотеки)
- системы для запуска кластеров в любом кластере или инструменте поставщика облачных вычислений.






# Удаленные функции



```
import time

@ray.remote
def add(x, y):
    time.sleep(1)
    return x + y
```

```
id1 = add.remote(1, 2)
id2 = add.remote(id1, 3)
id3 = add.remote(id2, 4)
id4 = add.remote(id3, 5)
id5 = add.remote(id4, 6)
id6 = add.remote(id5, 7)
id7 = add.remote(id6, 8)
result = ray.get(id7)
```



```
import time

@ray.remote
def add(x, y):
    time.sleep(1)
    return x + y
```

```
id1 = add.remote(1, 2)
id2 = add.remote(3, 4)
id3 = add.remote(5, 6)
id4 = add.remote(7, 8)
id5 = add.remote(id1, id2)
id6 = add.remote(id3, id4)
id7 = add.remote(id5, id6)
result = ray.get(id7)
```

# Акторы

При помощи одних только удаленных функций и вышеописанного обращения с задачами невозможно добиться, чтобы несколько задач одновременно работали над одним и тем же разделяемым изменяемым состоянием. Такая проблема при машинном обучении возникает в разных контекстах, где разделяемым может быть состояние симулятора, весовые коэффициенты в нейронной сети, что-нибудь совершенно иное.

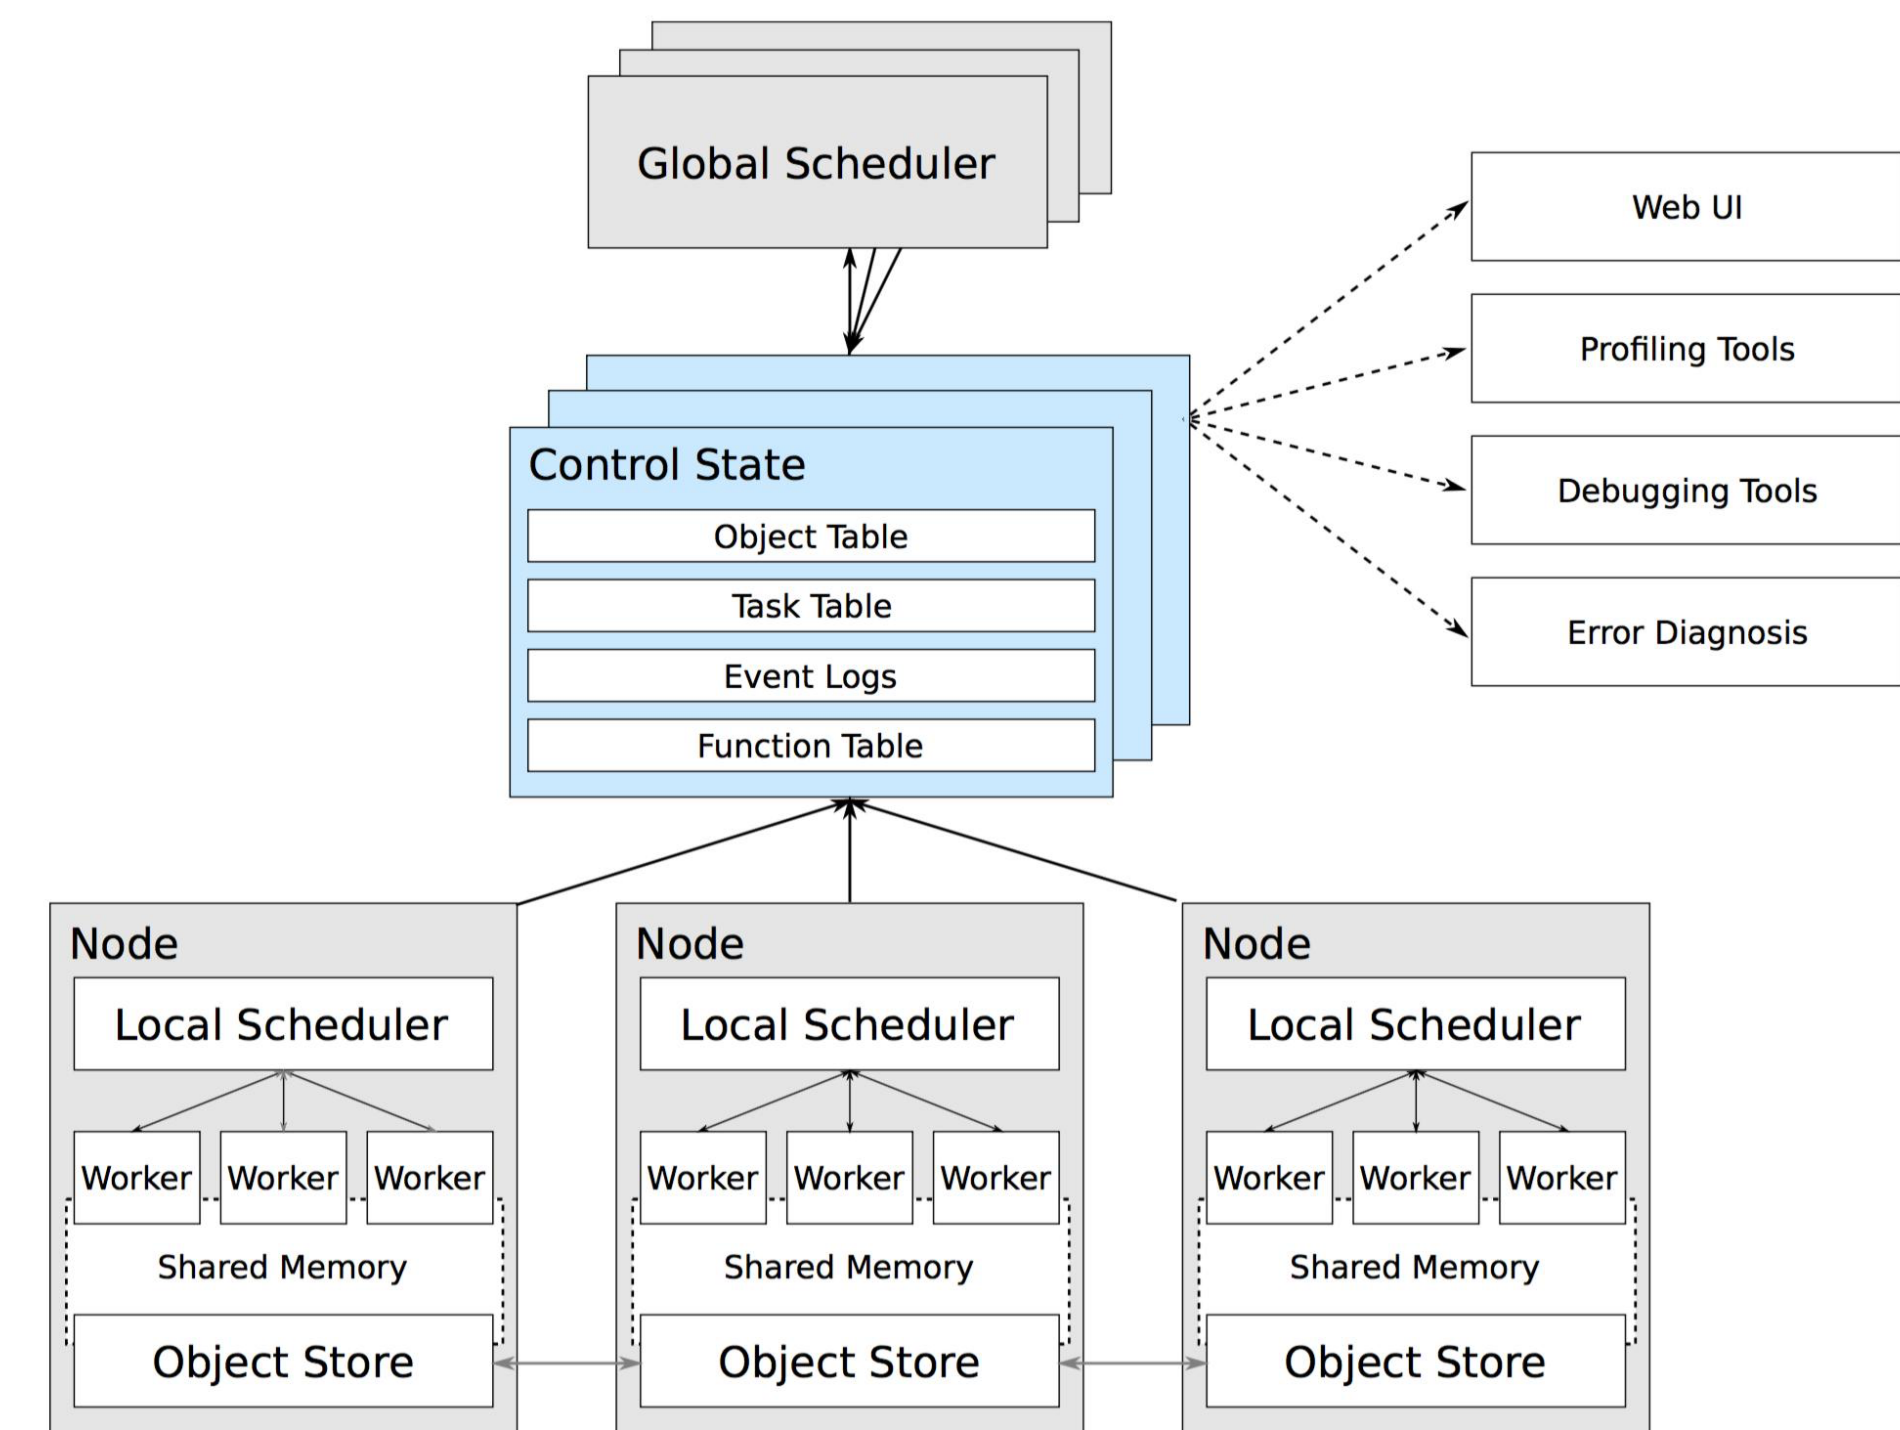
Абстракция актора используется в Ray для инкапсуляции изменяемого состояния, разделяемого между множеством задач.



# Системная архитектура

В качестве распределенной вычислительной системы Ray следует типичной конструкции Master-Slave: Master отвечает за глобальную координацию и поддержание состояния, а Slave выполняет задачи распределенных вычислений. В режиме кластерного развертывания Ray запустил следующие ключевые компоненты:

- **GlobalScheduler:** На главном устройстве запускается глобальный планировщик, который принимает задачи, представленные локальным планировщиком, и распределяет задачи по соответствующему локальному планировщику задач для выполнения.
- **RedisServer:** Запустите один или несколько RedisServers на главном сервере, чтобы сохранить информацию о состоянии (ControlState) распределенных задач.
- **LocalScheduler:** На каждом подчиненном сервере запускается локальный планировщик, который используется для отправки задач глобальному планировщику и назначения задач рабочему процессу на текущей машине.
- **Worker:** Каждое ведомое устройство может запускать несколько рабочих процессов для выполнения распределенных задач и сохранения результатов вычислений в ObjectStore.
- **ObjectStore:** Каждый Slave запускает ObjectStore для хранения объектов данных, доступных только для чтения. Работники могут получить доступ к этим данным объекта через общую память, что может эффективно снизить стоимость копирования памяти и сериализации объектов. Нижний уровень ObjectStore реализован Apache Arrow.



# Основные операции

`ray.init()` - запустить ray локально

`ray.put()` - сохранить объекты в локальном ObjectStore и асинхронно возвращать уникальный ObjectID.

`ray.get()` - получить объекты из ObjectStore через ObjectID и преобразовать их в объекты

`ray.wait()` - ожидание

`ray.error_info()` - получить информацию об ошибке

# Ray Train

Ray Train - библиотека, позволяющая упростить распределенное обучение.

**Frameworks:** Ray Train создан для абстрагирования от настройки координации / конфигурации распределенных фреймворков глубокого обучения, таких как Pytorch Distributed и Tensorflow Distributed, позволяя пользователям сосредоточиться только на реализации логики обучения.

- Для Pytorch Ray Train автоматически обрабатывает построение распределенной группы процессов
- Для Tensorflow Ray Train автоматически обрабатывает координацию TF\_CONFIG. Текущая реализация предполагает, что пользователь будет использовать MultiWorkerMirroredStrategy стратегию, но в ближайшем будущем это изменится.



# Практические результаты

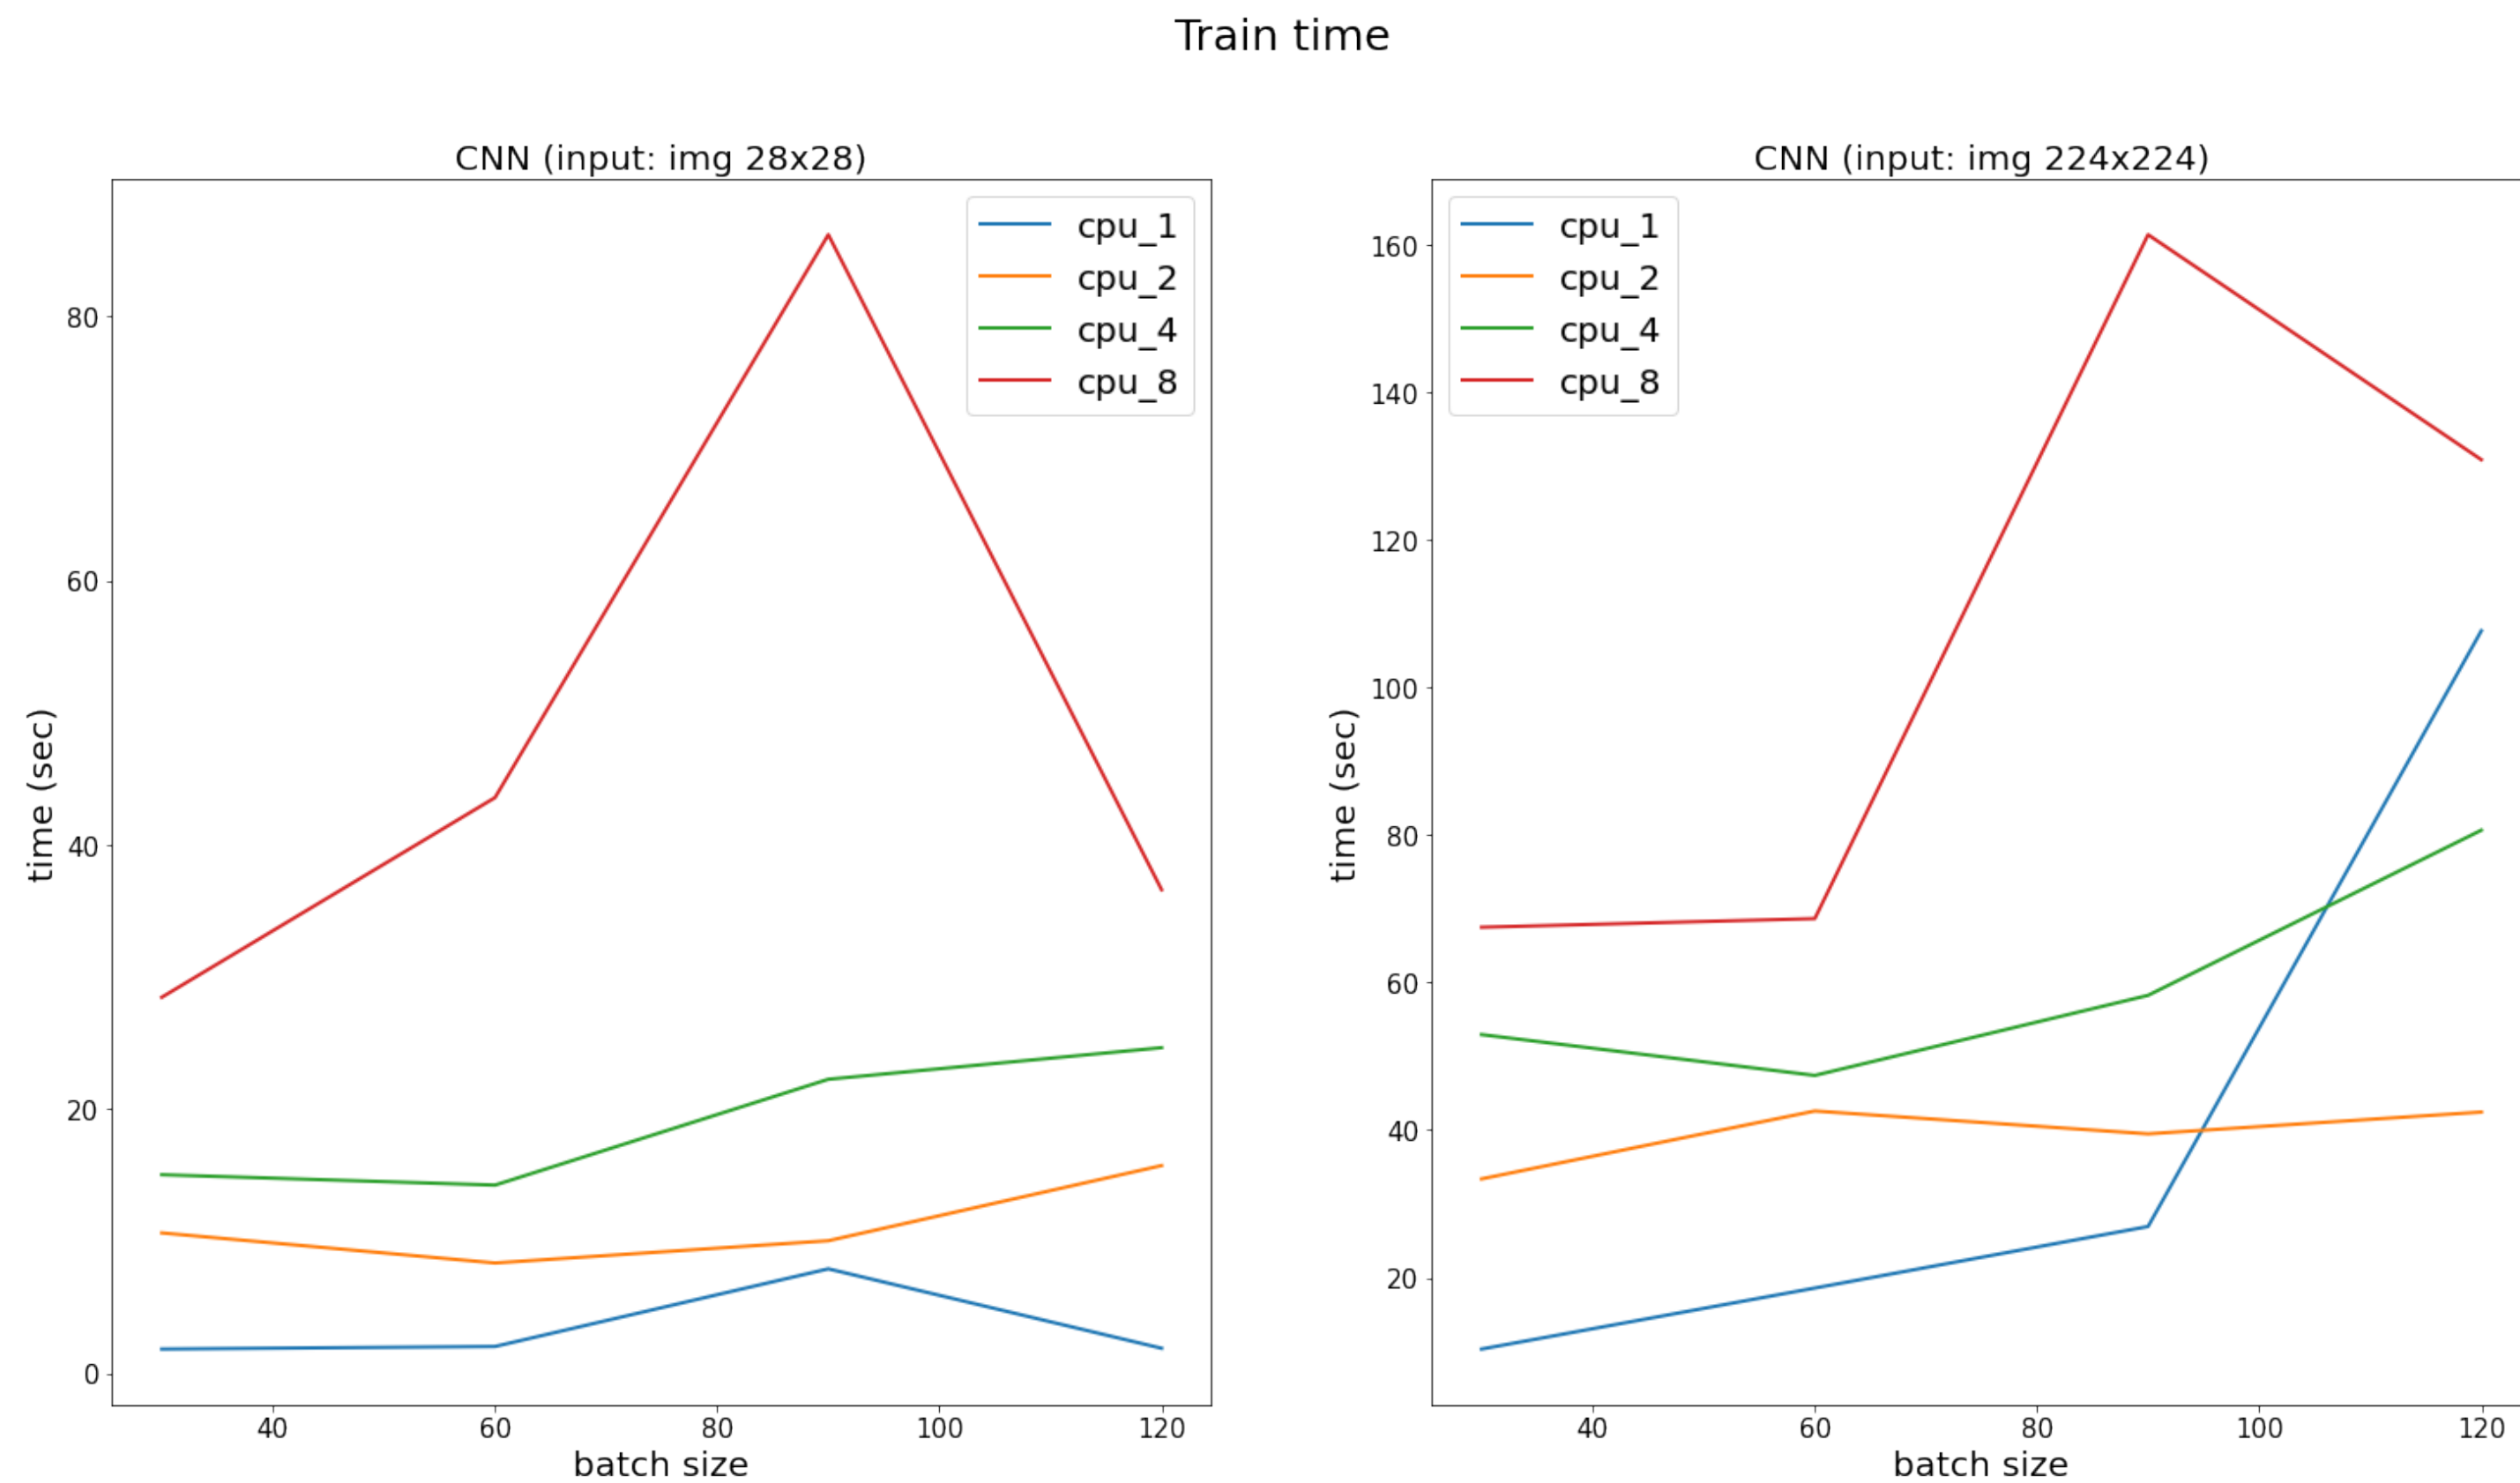
Ray Train использовался во время обучения 2 моделей (tensorflow):

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	(None, 24, 24, 6)	156
max_pooling2d_2 (MaxPooling 2D)	(None, 12, 12, 6)	0
conv2d_3 (Conv2D)	(None, 8, 8, 16)	2416
max_pooling2d_3 (MaxPooling 2D)	(None, 4, 4, 16)	0
flatten_1 (Flatten)	(None, 256)	0
dense_3 (Dense)	(None, 120)	30840
dense_4 (Dense)	(None, 84)	10164
dense_5 (Dense)	(None, 10)	850
Total params: 44,426 Trainable params: 44,426 Non-trainable params: 0		

Layer (type)	Output Shape	Param #
conv2d_4 (Conv2D)	(None, 224, 224, 32)	896
max_pooling2d_4 (MaxPooling 2D)	(None, 112, 112, 32)	0
conv2d_5 (Conv2D)	(None, 112, 112, 64)	18496
max_pooling2d_5 (MaxPooling 2D)	(None, 56, 56, 64)	0
flatten_2 (Flatten)	(None, 200704)	0
dense_6 (Dense)	(None, 2)	401410
Total params: 420,802 Trainable params: 420,802 Non-trainable params: 0		

# Практические результаты

Сравнение скорости обучения с применением Ray Train и без:



# Источники

- <https://docs.ray.io/en/latest/train/train.html>
- <https://github.com/LuckyZXL2016/Machine-Learning-Papers/blob/master/Ray/Ray%2CA%20Distributed%20Framework%20for%20Emerging%20AI%20Applications.pdf>
- <https://habr.com/ru/company/piter/blog/420695/>
- <https://www.codetd.com/ru/article/12526970>
- <https://www.machinelearningmastery.ru/modern-parallel-and-distributed-python-a-quick-tutorial-on-ray-99f8d70369b8/>
- <https://russianblogs.com/article/92751001142/>
- <https://russianblogs.com/article/18301057190/>
- <https://github.com/LuckyZXL2016/Machine-Learning-Papers/blob/master/Ray/Real-Time%20Machine%20Learning%20The%20Missing%20Pieces.pdf>
- <https://github.com/ray-project/ray>